

1. Частотный подход к построению статистических моделей. Требования к функции оценивания.

Частотная (классическая или ортодоксальная) статистика основана на концепции выборочного распределения. Это - распределение, что у оценщика δ есть, когда относится несколько набор данных $\mathcal{D}_1, \mathcal{D}_2 \dots \mathcal{D}_K$ выбранный от истинных, но неизвестных распределений. Оценка параметра - $\hat{\theta} = \delta \mathcal{D}$.

Выбрав оценщик, мы определяем его ожидаемую потерю или риск как

$$R(\theta^*, \delta) \triangleq \mathbb{E}_{p(\tilde{\mathcal{D}}|\theta^*)}[L(\theta^*, \delta(\tilde{\mathcal{D}}))] = \int L(\theta^*, \delta(\tilde{\mathcal{D}}))p(\tilde{\mathcal{D}}|\theta^*)d\tilde{\mathcal{D}},$$

где \mathcal{D} - данные, выбранные "природные" распределения, которые представлено параметром θ^* .

2. Квадратический дискриминантный анализ. Порядок получения формулы оценки вероятности $p(\mathbf{x}|\mathbf{y}=\mathbf{c}, \theta)$

Квадратичный дискриминантный анализ (QDA) является нелинейным обобщением метода LDA, который не использует предположения об однородности ковариационной матрицы.

В качестве решающего правила применяется квадратичная функция

$$d_k = -0.5(\mathbf{x} - \boldsymbol{\mu}_k)^T \mathbf{C}_k^{-1}(\mathbf{x} - \boldsymbol{\mu}_k) - 0.5 \ln |\mathbf{C}_k| + \ln \pi_k,$$

где

$|\mathbf{C}_k|$ - детерминант ковариационной матрицы k-го класса,

\mathbf{C}_k^{-1} - ее обратная матрица;

π_k - априорная вероятность наблюдения объектов k-го класса.

Экзаменуемый объект так же относится к классу с максимальным значением d_k

Gaussian Discriminant Analysis (2/3)

By plugging in the definition of Gaussian density the posteriors over the class labels, we obtain **quadratic discriminant analysis**:

$$p(\mathbf{x}|y = c, \boldsymbol{\theta}) = \frac{\pi_c |2\pi\boldsymbol{\Sigma}_c|^{-\frac{1}{2}} \exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1}(\mathbf{x} - \boldsymbol{\mu}_c)\right]}{\sum_{\hat{c}} \pi_{\hat{c}} |2\pi\boldsymbol{\Sigma}_{\hat{c}}|^{-\frac{1}{2}} \exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_{\hat{c}})^T \boldsymbol{\Sigma}_{\hat{c}}^{-1}(\mathbf{x} - \boldsymbol{\mu}_{\hat{c}})\right]}$$

Consider a special case in which the covariance matrices are tied or shared across classes ($\boldsymbol{\Sigma}_c = \boldsymbol{\Sigma}$):

$$p(\mathbf{x}|y = c, \boldsymbol{\theta}) \propto \exp\left[\boldsymbol{\mu}_c^T \boldsymbol{\Sigma}^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_c^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_c + \log[\pi_c]\right] \exp\left[-\frac{1}{2} \mathbf{x}^T \boldsymbol{\Sigma}^{-1} \mathbf{x}\right]$$

Let us define:

$$\gamma_c = -\frac{1}{2} \boldsymbol{\mu}_c^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_c + \log[\pi_c]$$

$$\boldsymbol{\beta}_c = \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_c$$

Gaussian Discriminant Analysis (3/3)

Then we can write:

$$p(\mathbf{x}|y = c, \boldsymbol{\theta}) = \frac{\exp[\boldsymbol{\beta}_c^T \mathbf{x} + \gamma_c]}{\sum_{\hat{c}} \exp[\boldsymbol{\beta}_{\hat{c}}^T \mathbf{x} + \gamma_{\hat{c}}]} = \mathcal{S}(\boldsymbol{\eta})_c$$

where $\boldsymbol{\eta} = [\boldsymbol{\beta}_1^T \mathbf{x} + \gamma_1, \dots, \boldsymbol{\beta}_C^T \mathbf{x} + \gamma_C]$, and \mathcal{S} is softmax function defined as:

$$\mathcal{S}(\boldsymbol{\eta})_c = \frac{e^{\eta_c}}{\sum_{\hat{c}=1}^C e^{\eta_{\hat{c}}}}$$

If we take logs, we end up with linear function of \mathbf{x} (because $\mathbf{x}^T \boldsymbol{\Sigma}^{-1} \mathbf{x}$ cancels from numerator/denominator). Thus the decision boundary between any two classes will be a straight line. Hence this technique is called **linear discriminant analysis (LDA)**.

3. Определить параметры модели GMM по заданной эмпирической выборке:

$\mathbf{x} = \{(1,2); (1,4); (-4, 0); (0, 10); (3, 5); (-7, 12)\}$

Mixtures of Gaussians (Gaussian Mixture Model):

$$p(\mathbf{x}_i | \boldsymbol{\theta}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

